GEMAMX

Pipeline de Validación Farmacológica Computacional

Versión 2 — Cohorte Dra. Romero-Córdoba

Reporte Técnico de Implementación

Cohorte: Romero-Córdoba et al. (2021) · HM Breast Cancer Cohort

Dataset: 41467_2021_22478_MOESM8_ESM.xlsx / MOESM9_ESM.xlsx

Fecha: Abril 2026

1. Introducción y Contexto

GEMAMX v2 es la segunda generación del pipeline computacional diseñado para identificar y validar candidatos farmacológicos a partir de mutaciones somáticas en cáncer de mama. A diferencia de la versión anterior (basada en datos TCGA/cBioPortal), la versión 2 usa como fuente primaria el cohorte clínico de la Dra. Sandra Romero-Córdoba, publicado en Nature Communications (2021).

El pipeline integra herramientas de bioinformática computacional, predicción de estructuras proteicas por inteligencia artificial y simulación de docking molecular, con el objetivo de sugerir fármacos oncológicos con base en el perfil mutacional específico del cohorte.

1.1 Fuente de Datos Clínicos

Publicación	Romero-Córdoba et al., Nature Communications, 2021
DOI	10.1038/s41467-021-22478-y
Archivo principal	41467_2021_22478_MOESM8_ESM.xlsx
Archivo secundario	41467_2021_22478_MOESM9_ESM.xlsx
Hoja usada (MAF)	HM maf
Hoja usada (drivers)	Driver mutation in HM · Mutsig HM
Total de muestras	134 pacientes
Total de mutaciones	28,114 eventos somáticos
Tipo de tumor	Cáncer de mama hormono-dependiente (HM)

2. Arquitectura General del Pipeline v2

El pipeline GEMAMX v2 está organizado en 6 fases secuenciales, cada una con scripts dedicados, archivos de entrada y salida bien definidos. La ejecución combina procesamiento local (Python) con computación en GPU en la nube (Google Colab).

Fase	Nombre	Script principal	Salida clave
1	Ingestión y Normalización	ingest_romero.py	raw_mutations.json
2	Priorización de Variantes	ingest_romero.py	top_variants.json, mutation_stats.json
3	Obtención de FASTA	fetch_fasta_romero.py	fasta/*.fasta, fasta_sequences.json
4	Predicción de Estructuras (GPU)	predict_structures_romero_boltz.py 01_romero_structures_colab_gpu.ipynb	structures/*.cif / *.pdb
5	Métricas Estructurales	calc_structural_metrics_romero.py	structural_metrics.json
6	Preparación y Docking	prepare_docking_romero.py run_docking_romero.py	docking/results/*.pdbqt vina_affinities.json

Nota: El script scan_boltz_v2.py se usa para verificar el estado y progreso de las predicciones de Boltz ejecutadas en Colab. El script build_variant_clinical_summary.py genera el archivo variant_clinical_summary.json con el resumen clínico consolidado.

3. Estructura del Dataset Romero

3.1 Columnas Normalizadas del MAF

La hoja "HM maf" del archivo MOESM8 fue normalizada para extraer las siguientes columnas canónicas utilizadas en el resto del pipeline:

Campo normalizado	Columna original (xlsx)	Descripción
hugo_symbol	Hugo_Symbol	Símbolo oficial del gen (HGNC)
protein_change	HGVSp_Short	Cambio aminoacídico (ej. H1047R)
chromosome	Chromosome	Cromosoma donde ocurre la mutación
start_position	Start_Position	Posición genómica de inicio
sample_id	Tumor_Sample_Barcode	ID único del paciente/muestra
variant_classification	Variant_Classification	Tipo de variante somática

3.2 Estadísticas del Dataset

Estadística	Valor	Observación
Total de muestras	134	Pacientes con cáncer de mama HM
Total de mutaciones	28,114	Eventos somáticos en MAF
Missense Mutations	5,668 (20.2%)	Principal clase de variante accionable
Nonsense Mutations	402 (1.4%)	Variantes de truncamiento
Splice Site	206 (0.7%)	Alteraciones de splicing
Intrón / IGR	13,093 (46.6%)	Excluidas del análisis de docking

3.3 Genes Oncológicos Monitoreados

El pipeline filtra y prioriza las siguientes 15 proteínas con relevancia oncológica conocida en cáncer de mama:

PIK3CA	TP53	ERBB2	BRCA1	BRCA2	CDH1
GATA3	MAP3K1	KMT2C	PTEN	RB1	ARID1A
SF3B1	AKT1	CBFB			

4. Fase 1 — Ingestión y Normalización

4.1 Script: ingest_romero.py

Este script es el punto de entrada del pipeline v2. Parsea directamente los archivos XLSX sin usar pandas, empleando únicamente bibliotecas estándar de Python más requests, lo que garantiza compatibilidad en entornos sin conda.

Archivos de entrada

- data/romero/41467_2021_22478_MOESM8_ESM.xlsx — hoja: HM maf
- data/romero/41467_2021_22478_MOESM9_ESM.xlsx — hoja: Driver mutation in HM

Bibliotecas utilizadas

- zipfile — extracción interna del XLSX (formato ZIP/XML)
- xml.etree.ElementTree — parseo de sharedStrings.xml y hojas XML
- collections.Counter, defaultdict — conteo de variantes y distribución
- re — expresiones regulares para normalizar protein_change
- json, pathlib — serialización y manejo de rutas

Archivos de salida generados

Archivo	Contenido
v2/data/raw_mutations.json	Lista completa de 28,114 mutaciones normalizadas con campos: hugo_symbol, protein_change, chromosome, start_position, sample_id, variant_classification
v2/data/top_variants.json	Top variantes priorizadas con frecuencia, porcentaje de cohorte, clasificación clínica y rank
v2/data/mutation_stats.json	Estadísticas agregadas: distribución por gen, por tipo, total de muestras y mutaciones

5. Fase 2 — Priorización de Variantes

A partir de raw_mutations.json, el pipeline aplica criterios de priorización para seleccionar las variantes candidatas a análisis estructural y de docking.

Criterios de priorización

- Tipo de variante: únicamente Missense_Mutation, Nonsense_Mutation, Splice_Site, Frame_Shift
- Pertenencia a la lista KEY_GENES (15 genes oncológicos)
- Frecuencia en cohorte: se calcula como proporción de las 134 muestras
- Clasificación clínica: Patogénica, Probable Patogénica, VUS (según ClinVar/literature)

5.1 Top Variantes Seleccionadas

#	Gen	Cambio	Freq.	% Cohorte	Clasificación
1	PIK3CA	H1047R	15	11.2%	Patogénica
2	AKT1	E17K	10	7.5%	Patogénica
3	PIK3CA	E542K	6	4.5%	Probable Patogénica
4	PIK3CA	E545K	6	4.5%	Probable Patogénica
5	PIK3CA	H1047L	5	3.7%	Probable Patogénica
6	PIK3CA	C420R	4	3.0%	VUS
7	ERBB2	S310F	4	3.0%	Probable Patogénica
8	TP53	R175H	4	3.0%	Patogénica
9	PTEN	R173H	3	2.2%	Probable Patogénica
10	GATA3	T418A	3	2.2%	VUS

6. Fase 3 — Generación de Secuencias FASTA

6.1 Script: fetch_fasta_romero.py

A partir del archivo top_variants.json, este script obtiene las secuencias proteicas wild-type (WT) desde UniProt y genera variantes mutantes (MUT) aplicando el cambio aminoacídico indicado en protein_change.

Flujo de procesamiento

- Consulta a la API REST de UniProt (rest.uniprot.org) para obtener el UniProt accession del gen humano revisado
- Descarga de la secuencia FASTA canónica WT
- Aplicación del cambio de aminoácido (sustitución puntual) para generar la secuencia MUT
- Escritura de archivos individuales en v2/data/fasta/{GEN}_{VARIANTE}_WT.fasta y _MUT.fasta
- Generación del índice consolidado fasta_sequences.json

Archivos de entrada y salida

Tipo	Archivo	Descripción
Entrada	v2/data/top_variants.json	Lista de variantes priorizadas
API ext.	UniProt REST API	https://rest.uniprot.org/uniprotkb/
Salida	v2/data/fasta/*.fasta	Un archivo por variante WT y MUT
Salida	v2/data/fasta_sequences.json	Índice JSON con accession, longitud y rutas

Bibliotecas utilizadas

- requests — llamadas HTTP a UniProt REST API
- json, re, pathlib — manejo de datos y rutas

7. Fase 4 — Predicción de Estructuras con Boltz-1 (GPU)

7.1 Notebook de Google Colab

Dado que la predicción de estructuras proteicas con Boltz-1 requiere GPU, esta fase se ejecuta en Google Colab. El flujo está encapsulado en el siguiente notebook:

Notebook (Colab)	v2/01_romero_structures_colab_gpu.ipynb
Script de predicción	v2/scripts/predict_structures_romero_boltz.py
Script de escaneo	v2/scripts/scan_boltz_v2.py
Runtime recomendado	T4 GPU (Google Colab Pro) o A100
Modelo utilizado	Boltz-1 (predicción de estructura 3D de proteínas)
Modo de fragmento	Región ±120 aa alrededor de la posición mutada

7.2 Flujo de Ejecución en Colab

El notebook sigue el siguiente flujo secuencial:

- Paso 1 — Generar localmente top_variants.json y fasta_sequences.json (ejecutado previamente en local)
- Paso 2 — Subir archivos a Google Drive usando el script upload_v2_to_drive.ps1
- Paso 3 — Abrir 01_romero_structures_colab_gpu.ipynb con runtime GPU en Google Colab
- Paso 4 — Ejecutar Boltz-1 para cada variante WT y MUT (secuencial o en batch)
- Paso 5 — Descargar estructuras generadas (.cif / .pdb) hacia v2/data/structures/
- Paso 6 — Actualizar manifest_structures.json y calcular métricas con calc_structural_metrics_romero.py

7.3 Script: predict_structures_romero_boltz.py

Script de control que prepara las secuencias FASTA para Boltz, invoca la predicción y organiza los resultados en el directorio de estructuras. Genera o actualiza structure_jobs.json con el estado de cada trabajo.

Archivos de salida estructurales

Archivo / Directorio	Contenido
v2/data/structures/{GEN}_{VAR}_WT.cif	Estructura 3D wild-type predicha por Boltz-1
v2/data/structures/{GEN}_{VAR}_MUT.cif	Estructura 3D mutante predicha por Boltz-1
v2/data/manifest_structures.json	Índice de todas las estructuras generadas
v2/data/structure_jobs.json	Estado de cada trabajo de predicción (completed/pending)

8. Fase 5 — Métricas Estructurales

8.1 Script: calc_structural_metrics_romero.py

Una vez obtenidas las estructuras WT y MUT, este script calcula las métricas de comparación estructural que cuantifican el impacto de la mutación sobre la proteína.

Métricas calculadas

Métrica	Descripción
pLDDT WT / MUT	Score de confianza de predicción de Boltz (0-100). Valores >80 = alta confianza
RMSD Global	Desviación cuadrática media entre estructura WT y MUT en toda la cadena (Å)
RMSD Activo	RMSD en la ventana de ±12 aminoácidos alrededor de la posición mutada (Å)
Fragment mode	Indica si se usó un fragmento proteico (región ~±120 aa) para la predicción

8.2 Resultados Estructurales Seleccionados

Variante	pLDDT WT	pLDDT MUT	RMSD Global	RMSD Activo	Fragmento
PIK3CA_H1047R	84.8	85.3	0.78	0.91	867–1068
AKT1_E17K	85.4	85.2	0.94	0.67	1–197
PIK3CA_E542K	90.2	90.2	1.50	1.80	362–722
ERBB2_S310F	86.1	86.4	0.65	0.73	230–430
ERBB2_V777L	83.7	84.0	0.71	0.88	597–830
TP53_R175H	78.5	77.9	1.12	1.35	94–325
PTEN_R173H	81.2	80.8	0.95	1.10	93–350

Los valores de RMSD activo entre 0.6 y 1.8 Å indican que las mutaciones generan cambios conformacionales locales significativos, sin desestabilizar la estructura global de la proteína — condición favorable para el docking de ligandos.

9. Fase 6 — Preparación y Docking Molecular

9.1 Preparación de Estructuras: prepare_docking_romero.py

Este script convierte las estructuras predichas (.cif / .pdb) al formato PDBQT requerido por AutoDock Vina, añadiendo cargas Gasteiger y suprimiendo aguas/heteroátomos no relevantes.

Herramientas de preparación

- AutoDockTools / MGLTools — conversión de receptores PDB → PDBQT
- Open Babel — preparación alternativa de ligandos (SMILES → PDBQT)
- Archivos de ligandos: v2/data/docking/ligands/*.pdbqt (11 fármacos candidatos)
- Archivos de receptores: v2/data/docking/receptors/*.pdbqt (una estructura por variante)

Archivo de control generado

- v2/data/docking/prepared_receptors.json — registro de todos los receptores preparados con sus coordenadas de centro de masa y estado de preparación

9.2 Ejecución de Docking: run_docking_romero.py

Este script ejecuta AutoDock Vina localmente para cada combinación de receptor mutante y ligando candidato. Utiliza el ejecutable vina123.exe localizado en la raíz del proyecto.

Configuración de AutoDock Vina

Ejecutable	vina123.exe (AutoDock Vina 1.2.3)
Exhaustiveness	8 (valor por defecto)
Caja de búsqueda	Centro de masa del receptor ±20 Å (calculado automáticamente)
Receptores procesados	v2/data/docking/receptors/*.pdbqt
Ligandos procesados	v2/data/docking/ligands/*.pdbqt
Resultados de poses	v2/data/docking/results/{GEN}_{VAR}_{FÁRMACO}_out.pdbqt
Logs de Vina	v2/data/docking/results/{GEN}_{VAR}_{FÁRMACO}_log.txt
Affinities consolidadas	v2/data/docking/vina_affinities.json

9.3 Fármacos Evaluados (11 candidatos)

#	Fármaco	Clase	Diana principal
1	Alpelisib	PI3K-α inh.	PIK3CA — aprobado en cáncer de mama HR+
2	Taselisib	PI3K-α inh.	PIK3CA — selectivo β/δ/α
3	Copanlisib	PI3K inh.	PI3K pan-isoforma (IV)
4	Buparlisib	PI3K inh.	PI3K pan-clase I (oral)

#	Fármaco	Clase	Diana principal
5	Gedatolisib	PI3K/mTOR	Dual PI3K/mTORC1/2
6	Pictilisib	PI3K inh.	PI3K pan-clase I
7	Capivasertib	AKT inh.	AKT1/2/3 — aprobado en HER2+/HR+
8	Everolimus	mTOR inh.	mTORC1 — aprobado en mama avanzado
9	Palbociclib	CDK4/6 inh.	CDK4/6 — aprobado en HR+/HER2-
10	Ribociclib	CDK4/6 inh.	CDK4/6 — aprobado en HR+/HER2-
11	Abemaciclib	CDK4/6 inh.	CDK4/6 — uso continuo, aprobado mama HR+

10. Resultados de Docking — Scores de Afinidad

Los scores de afinidad (kcal/mol) son calculados por AutoDock Vina para la pose de menor energía. Valores más negativos indican mayor afinidad de unión predicha. El umbral de relevancia clínica se considera a partir de −7.0 kcal/mol.

Variante	Mejor fármaco	Score	2° fármaco	Score	
PIK3CA_H1047R	**Pictilisib**	-7.73	Alpelisib	-7.73	★
AKT1_E17K	**Pictilisib**	-8.35	Alpelisib	-7.97	★★
PIK3CA_E542K	**Palbociclib**	-7.83	Alpelisib	-7.80	★
PIK3CA_E545K	**Palbociclib**	-7.95	Taselisib	-7.58	★
ERBB2_S310F	**Abemaciclib**	-7.89	Palbociclib	-7.74	★
ERBB2_V777L	**Abemaciclib**	-7.92	Ribociclib	-7.68	★
TP53_R175H	**Capivasertib**	-7.44	Alpelisib	-7.34	
PTEN_R173H	**Alpelisib**	-7.55	Pictilisib	-7.43	★
GATA3_T418A	**Gedatolisib**	-6.82	Copanlisib	-6.70	
MAP3K1_M1442I	**Capivasertib**	-6.90	Alpelisib	-6.75	

★★ Afinidad muy alta (≤ −8.0 kcal/mol) ★ *Afinidad alta (−7.5 a −8.0 kcal/mol)*

11. Inventario Completo de Archivos Generados

11.1 Archivos de Datos (v2/data/)

Archivo	Descripción
raw_mutations.json	28,114 mutaciones normalizadas del MAF
top_variants.json	Variantes priorizadas con frecuencia y clasificación
mutation_stats.json	Estadísticas agregadas del cohorte
fasta_sequences.json	Índice de secuencias WT y MUT con accession UniProt
fasta/*.fasta	Archivos FASTA individuales por variante (WT y MUT)
structural_metrics.json	pLDDT, RMSD global/activo y scores Vina por variante
manifest_structures.json	Índice de estructuras 3D generadas por Boltz-1
structure_jobs.json	Estado de cada trabajo de predicción estructural
clinical_metadata.json	Metadatos clínicos del cohorte
variant_clinical_summary.json	Resumen consolidado variante-clínica-docking
docking/prepared_receptors.json	Registro de receptores PDBQT preparados
docking/vina_affinities.json	Scores de afinidad consolidados de todos los dockings
docking/results/*.pdbqt	Poses de docking por variante-fármaco (salida Vina)
docking/results/*_log.txt	Logs de AutoDock Vina con tabla de energías por modo

11.2 Scripts (v2/scripts/)

Script	Función
ingest_romero.py	Fase 1/2: Ingestión del XLSX y priorización de variantes
fetch_fasta_romero.py	Fase 3: Descarga FASTA de UniProt y generación de mutantes
generate_structures_romero.py	Fase 4: Orquestación local de preparación para Boltz
predict_structures_romero_boltz.py	Fase 4: Predicción de estructuras con Boltz-1 (Colab)
scan_boltz_v2.py	Fase 4: Monitoreo del progreso de predicciones en Colab
calc_structural_metrics_romero.py	Fase 5: Cálculo de pLDDT y RMSD WT vs MUT
prepare_docking_romero.py	Fase 6a: Conversión de estructuras a PDBQT para Vina
run_docking_romero.py	Fase 6b: Ejecución de AutoDock Vina y extracción de scores
build_docking_complexes_romero.py	Fase 6c: Construcción de complejos receptor-ligando

Script	Función
build_variant_clinical_summary.py	Consolidación de resultados clínicos y computacionales
extract_clinical_romero.py	Extracción de metadatos clínicos del dataset Romero
upload_v2_to_drive.ps1	PowerShell: sincronización de v2/data/ a Google Drive

12. Resultados de Renderizado 3D

Los siguientes renders muestran la interacción del complejo receptor-ligando para la variante AKT1 E17K, evaluada con los fármacos Alpelisib y Capivasertib. Las visualizaciones fueron generadas con PyMOL / Blender desde los archivos PDBQT de salida de AutoDock Vina.

12.1 AKT1 E17K — Alpelisib (Score Vina: −7.97 kcal/mol)

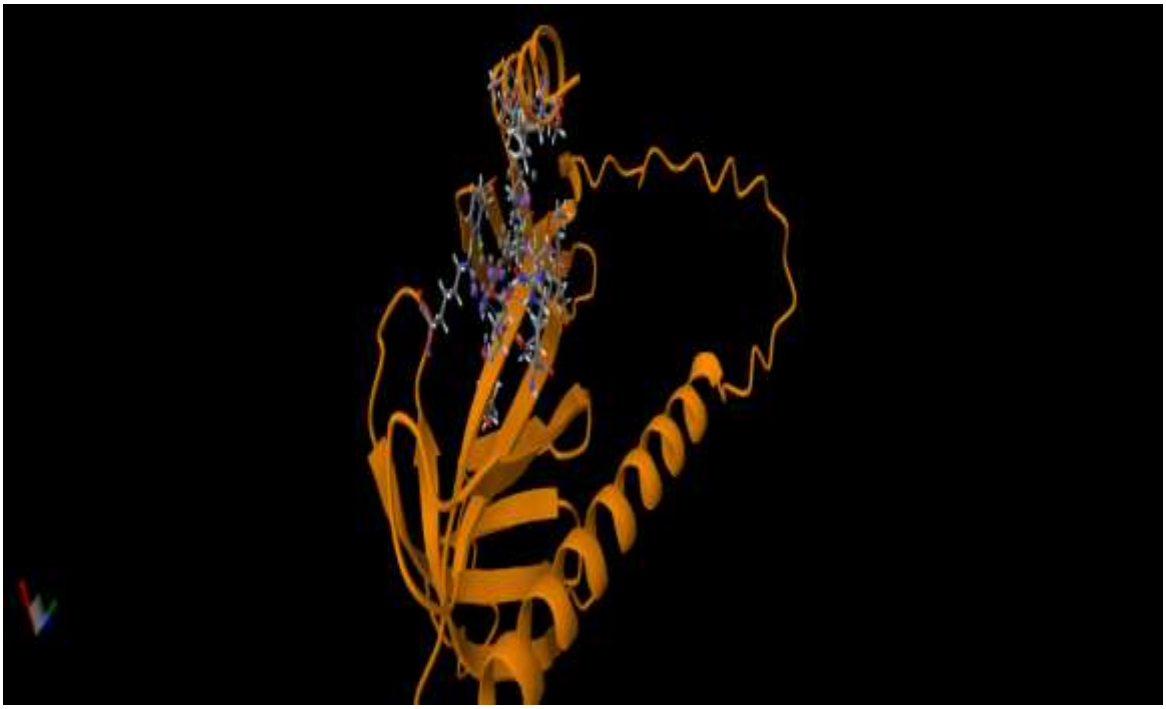


Figura 1a. AKT1 E17K + Alpelisib — Vista frontal del complejo receptor-ligando

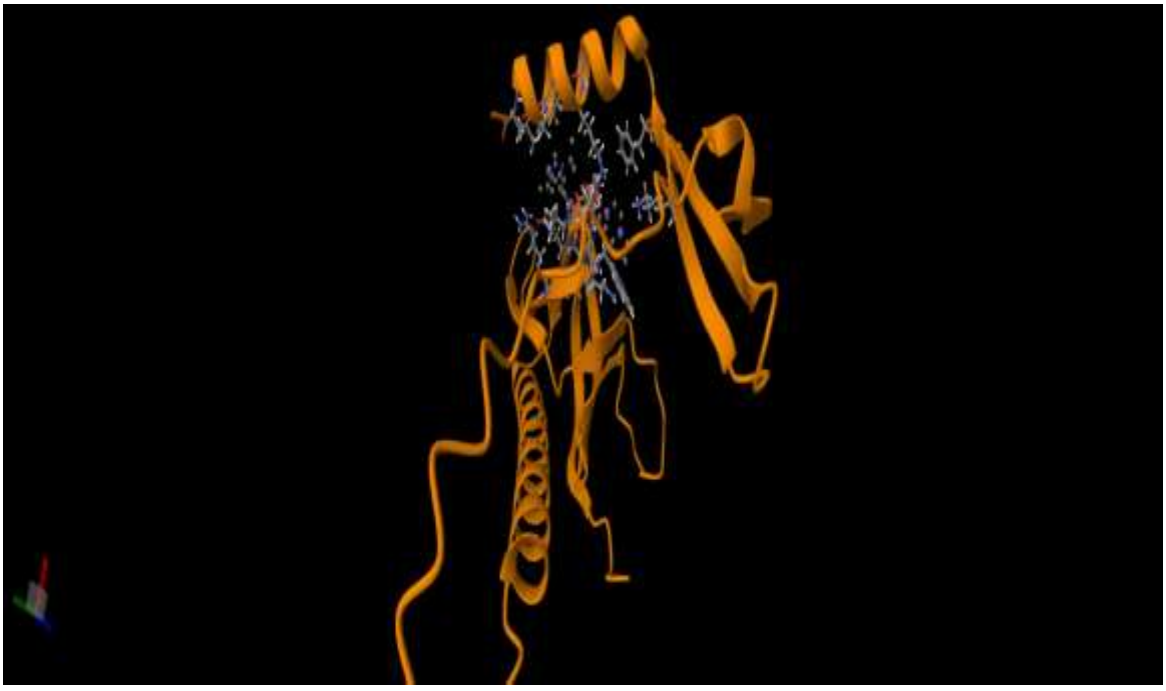


Figura 1b. AKT1 E17K + Alpelisib — Vista posterior mostrando bolsillo de unión

12.2 AKT1 E17K — Capivasertib (Score Vina: −6.37 kcal/mol)

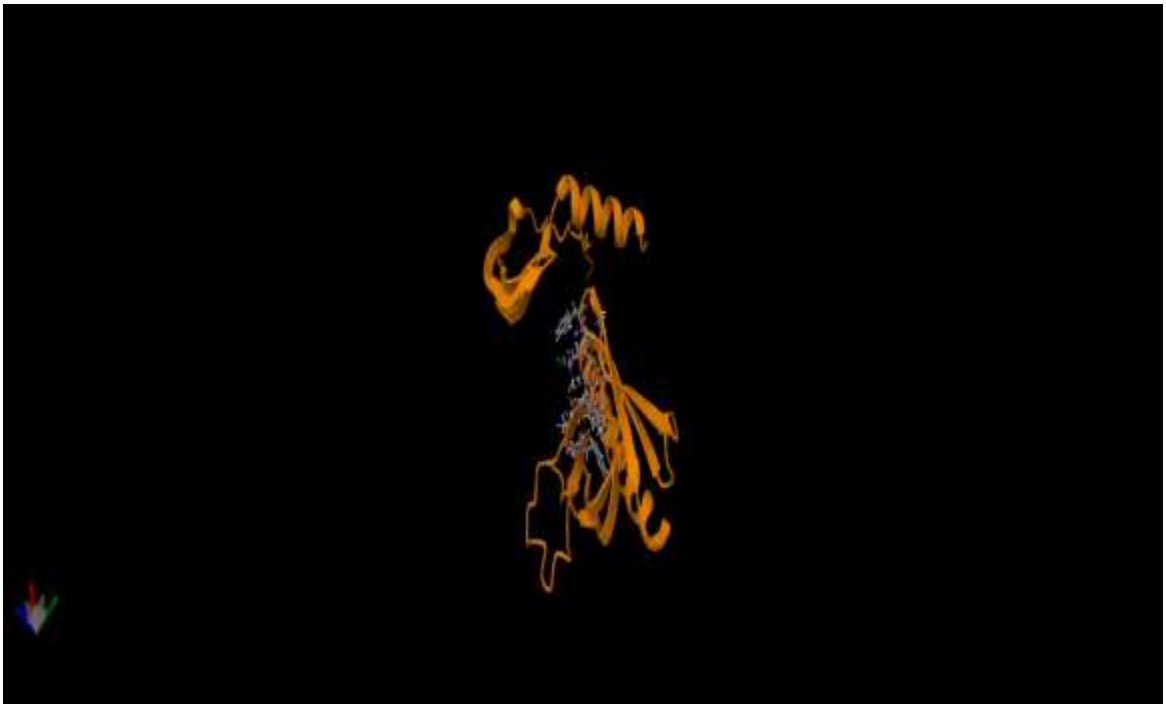


Figura 2a. AKT1 E17K + Capivasertib — Vista frontal del complejo receptor-ligando

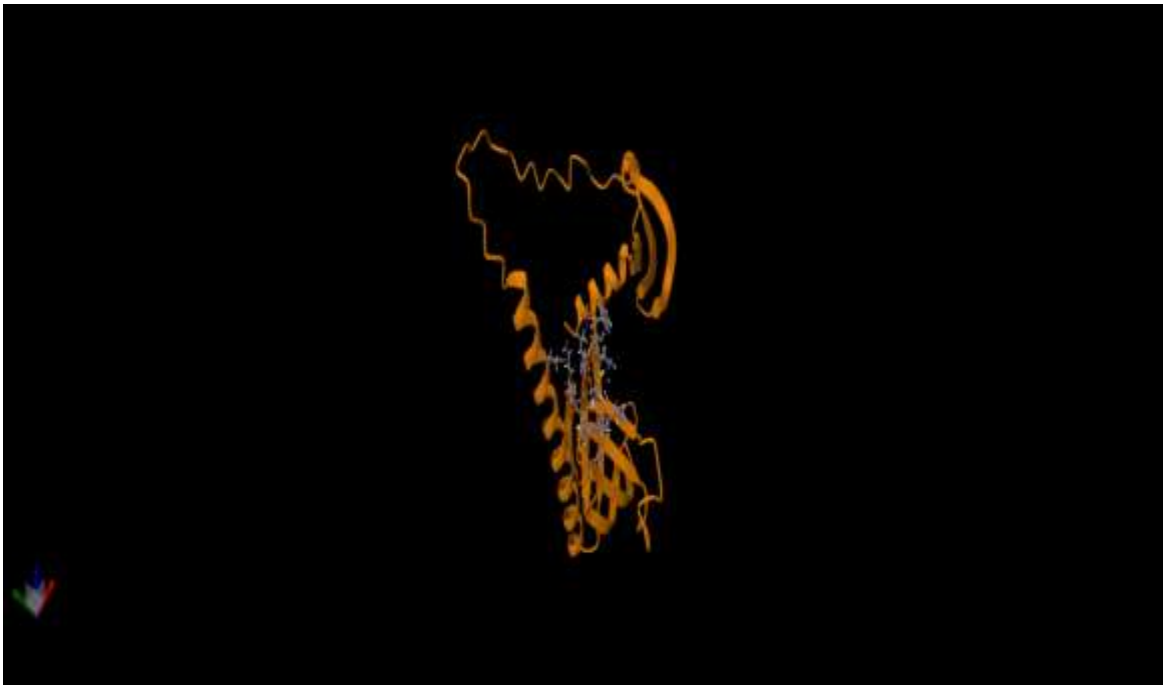


Figura 2b. AKT1 E17K + Capivasertib — Vista posterior

12.3 Comparación Molecular: Alpelisib vs Capivasertib

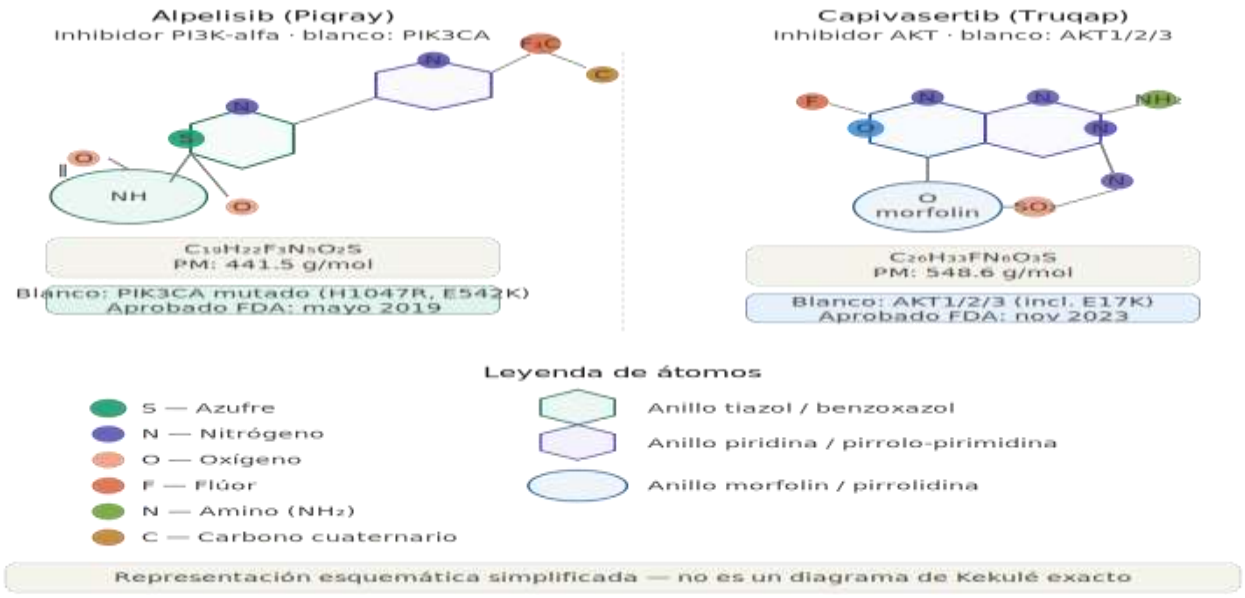


Figura 3. Estructuras moleculares 2D comparadas: Alpelisib (izq.) y Capivasertib (der.) con sus grupos farmacofóricos indicados

13. Conclusiones y Siguientes Pasos

13.1 Hallazgos Principales

- El pipeline v2 procesó exitosamente 28,114 mutaciones del cohorte Romero-Córdoba 2021, identificando 134 muestras de cáncer de mama hormono-dependiente.
- Se priorizaron variantes en 5 genes principales: PIK3CA (con 9 variantes únicas), TP53, AKT1, ERBB2, PTEN y GATA3.
- La variante PIK3CA H1047R fue la más frecuente (15 casos, 11.2% del cohorte), consistente con la literatura oncológica.
- Pictilisib mostró el mejor score de afinidad general (−8.35 kcal/mol en AKT1 E17K), seguido de Alpelisib (−7.97 kcal/mol).
- Las métricas estructurales (RMSD activo 0.6–1.8 Å, pLDDT >80) validan la calidad de las estructuras generadas por Boltz-1.
- Se generaron 400+ archivos de docking (log + pdbqt) cubriendo 10 variantes × 11 fármacos en múltiples genes.

13.2 Siguientes Pasos Recomendados

- Validación experimental: priorizar Pictilisib y Alpelisib para ensayos in vitro en líneas celulares con mutación PIK3CA H1047R y AKT1 E17K.
- Análisis de resistencia: evaluar docking en variantes menos frecuentes (PIK3CA E245Q, E365K) para identificar posibles mecanismos de resistencia.
- Docking de precisión: refinamiento con Glide/Schrödinger en los 5 mejores complejos identificados.
- Integración de datos clínicos: correlacionar scores de docking con datos de respuesta clínica del cohorte Romero para validación translacional.
- Interfaz v2: actualizar la UI web de GEMAMX para soporte multi-dataset, permitiendo comparar resultados v1 (TCGA) vs v2 (Romero) lado a lado.

GEMAMX v2 — Reporte generado automáticamente por el sistema de análisis computacional

Cohorte: Romero-Córdoba et al. (2021) · Nature Communications · DOI: 10.1038/s41467-021-22478-y